



ONEBYTE
SOLUTIONS

TRABAJO DE INVESTIGACIÓN TI-06

FinOps

economía y optimización de costos en la nube

Análisis de la disciplina que conecta las decisiones de arquitectura y operación con la gestión económica de servicios cloud.

ASIGNATURA

ICI-5444 · Taller de Formulación de Proyectos Informáticos

EMPRESA

N.º 8 · ONEBYTE

FECHA DE ENTREGA

21 de septiembre de 2026

DOCENTE Antonio Moya Villegas

INTEGRANTES Vicente Morales · Danilo Álvarez · Matías Villegas · Cristofer Contreras · Lucas Erazo · Matías Romero · José Villamayor · Pablo Silva

00

ESTRUCTURA DEL INFORME

Contenido

1	Introducción y contexto	1
1.1	Resumen ejecutivo	1
1.2	Contexto de la computación en la nube	1
1.3	Problema de la gestión de costos cloud	1
1.4	Pregunta orientadora del informe	1
1.5	Objetivo general	1
1.6	Objetivos específicos	1
1.7	Alcance del informe	1
1.8	Metodología y criterios de selección de fuentes	1
1.9	Identificación del aporte propio del grupo	1
2	Fundamentos de FinOps	2
2.1	Conceptos previos para comprender FinOps	2
2.2	Definición operativa de FinOps	2
2.3	Qué es y qué no es FinOps	2
2.4	FinOps como gestión del valor y no solo reducción de costos	2
2.5	Fases del marco FinOps	2
2.6	Roles y responsabilidades	2
3	De los datos de costo a las decisiones	3
3.1	Visibilidad y asignación de costos	3
3.2	Etiquetado de recursos	3
3.3	Showback y chargeback	3
3.4	Costos compartidos y tasas de asignación	3
3.5	Economía unitaria	3
3.6	Costos subestimados en la nube	3
3.7	Palancas de optimización	3
3.8	Compromisos entre costo, calidad, velocidad y riesgo	3
4	Ecosistema FinOps y contexto cloud	4
4.1	Estandarización de facturación multinube	4
4.2	Especificación FOCUS	4
4.3	Estimación temprana de costos	4
4.4	Herramientas nativas de los proveedores cloud	4
4.5	Plataformas multinube	4
4.6	Herramientas para costos en Kubernetes	4
4.7	Herramientas de estimación temprana	4
4.8	Criterios de comparación	4
4.9	Comparación de herramientas y proveedores	4
4.10	Alternativas adicionales identificadas por el grupo	4
4.11	Regiones cloud en Chile y Sudamérica	4
4.12	Disponibilidad, precios y residencia de datos	4
5	Caso aplicado y evaluación económica	5
5.1	Contexto y necesidad de ONEBYTE	5
5.2	Arquitectura de referencia	5
5.3	Componentes y servicios utilizados	5

5.4	Supuestos técnicos, operativos y económicos	5
5.5	Volumen de usuarios, solicitudes y almacenamiento	7
5.6	Costo base mensual y anual	7
5.7	Costo total de propiedad a cinco años	7
5.8	Aplicación de la primera palanca de optimización	7
5.9	Aplicación de la segunda palanca de optimización	7
5.10	Aplicación de la tercera palanca de optimización	8
5.11	Comparación entre Santiago de Chile y Estados Unidos	8
5.12	Análisis de sensibilidad	8
5.13	Variables de mayor impacto en la factura	8
5.14	Relación con el flujo de caja, VAN y TIR	8
5.15	Aporte propio aplicado al caso	9
6	Discusión y conclusiones	10
6.1	Interpretación de los resultados	10
6.2	Discusión crítica de las alternativas	10
6.3	Relación entre arquitectura y costos	10
6.4	Limitaciones y riesgos del análisis	10
6.5	Principales aportes propios del grupo	10
6.6	Recomendación para ONEBYTE	10
6.7	Conclusiones	10
	Referencias	11
A	Cuestionario de 30 preguntas	12
A.1	Índice temático	12
A.2	Preguntas, respuestas y justificaciones	12
B	Declaración de uso de inteligencia artificial	13
B.1	Registro de uso por sección e integrante	13
B.2	Prompts y evidencia trazable	13
B.3	Declaraciones individuales y firmas	13

01

CONTEXTO, OBJETIVOS Y ALCANCE

Introducción y contexto

- 1.1 Resumen ejecutivo
- 1.2 Contexto de la computación en la nube
- 1.3 Problema de la gestión de costos cloud
- 1.4 Pregunta orientadora del informe
- 1.5 Objetivo general
- 1.6 Objetivos específicos
- 1.7 Alcance del informe
- 1.8 Metodología y criterios de selección de fuentes
- 1.9 Identificación del aporte propio del grupo

02 MARCO CONCEPTUAL Fundamentos de FinOps

2.1 Conceptos previos para comprender FinOps

2.1.1 Consumo de servicios cloud

2.1.2 Costos variables y modelo bajo demanda

2.1.3 Diferencia entre costo, eficiencia y valor

2.2 Definición operativa de FinOps

2.3 Qué es y qué no es FinOps

2.4 FinOps como gestión del valor y no solo reducción de costos

2.5 Fases del marco FinOps

2.5.1 Informar

2.5.2 Optimizar

2.5.3 Operar

2.6 Roles y responsabilidades

2.6.1 Ingeniería

2.6.2 Finanzas

2.6.3 Adquisiciones

2.6.4 Negocio y producto

03

MEDICIÓN, ASIGNACIÓN Y OPTIMIZACIÓN

De los datos de costo a las decisiones

3.1 Visibilidad y asignación de costos

3.2 Etiquetado de recursos

3.3 Showback y chargeback

3.4 Costos compartidos y tasas de asignación

3.5 Economía unitaria

3.5.1 Costo por transacción

3.5.2 Costo por cliente atendido

3.5.3 Costo por solicitud

3.5.4 Costo por token de inteligencia artificial

3.6 Costos subestimados en la nube

3.6.1 Salida de datos a Internet

3.6.2 Tráfico entre zonas de disponibilidad

3.6.3 Licencias de software

3.6.4 Soporte

3.6.5 Ambientes no productivos

3.7 Palancas de optimización

3.7.1 Dimensionamiento correcto

3.7.2 Apagado de recursos ociosos

3.7.3 Descuentos por compromiso

3.7.4 Capacidad excedente

3.7.5 Niveles de almacenamiento

3.7.6 Optimización de la arquitectura

3.8 Compromisos entre costo, calidad, velocidad y riesgo

04

ESTÁNDARES, HERRAMIENTAS Y REGIONES

Ecosistema FinOps y contexto cloud

- 4.1 Estandarización de facturación multinube
- 4.2 Especificación FOCUS
- 4.3 Estimación temprana de costos
- 4.4 Herramientas nativas de los proveedores cloud
- 4.5 Plataformas multinube
- 4.6 Herramientas para costos en Kubernetes
- 4.7 Herramientas de estimación temprana
- 4.8 Criterios de comparación
- 4.9 Comparación de herramientas y proveedores
- 4.10 Alternativas adicionales identificadas por el grupo
- 4.11 Regiones cloud en Chile y Sudamérica
- 4.12 Disponibilidad, precios y residencia de datos

05

APLICACIÓN AL PROYECTO DEL CURSO

Caso aplicado y evaluación económica

5.1 Contexto y necesidad de ONEBYTE

Para aplicar los conceptos de FinOps al proyecto del curso se construyó un caso comparable para ONEBYTE: una API web contenedorizada desplegada en Microsoft Azure. El propósito no es describir un sistema productivo existente ni emitir una cotización, sino evaluar cómo las decisiones de arquitectura, región y operación modifican el costo cloud durante cinco años. El caso permite conectar una línea base técnica con tres palancas de optimización, una comparación regional, un análisis de sensibilidad y una evaluación financiera incremental.

La necesidad abordada es disponer de una estimación reproducible antes de comprometer presupuesto. Para ello se conserva la misma arquitectura y demanda en Chile Central y East US, se documentan las exclusiones y se separan siete estados de evidencia: oficial, supuesto documentado, proxy público, estimación de ingeniería, derivado verificado, pendiente humano y no aplica justificado. La matriz consolidada de FP-172 y FP-182 a FP-188 registra 94 entradas al 20-09-2026. Esta clasificación evita presentar una proyección académica como gasto observado de ONEBYTE.

5.2 Arquitectura de referencia

La arquitectura común recibe tráfico HTTPS desde Internet y ejecuta la API en Azure Container Apps, plan Consumption. La aplicación persiste datos transaccionales en Azure Database for PostgreSQL Flexible Server, almacena objetos en Blob Storage y envía telemetría a Azure Monitor. Las salidas hacia Internet se valorizan con Microsoft Premium Global Network. PostgreSQL usa respaldo automático de siete días y se modela sin alta disponibilidad, porque no existe todavía un requisito aprobado que justifique replicar cómputo y almacenamiento.

La arquitectura lógica, el horizonte, la moneda y la demanda permanecen constantes entre regiones. Solo cambian las tarifas y condiciones regionales documentadas. Este control es esencial: una diferencia de precio no sería atribuible a la región si también se cambiaran capacidad, disponibilidad o volumen de trabajo.

5.3 Componentes y servicios utilizados

Capa	Configuración evaluada	Tratamiento económico
Aplicación productiva	Container Apps Consumption; 1 vCPU, 2 GiB y 730 h/mes	Se aplican primero las franquicias mensuales de cómputo y solicitudes.
No producción	0,5 vCPU, 1 GiB, 264 h/mes y 100.000 solicitudes/mes	Puede escalar a cero fuera de la ventana definida.
Datos	PostgreSQL Flexible Server General Purpose, 2 vCores y 100 GiB	Dos vCores es el mínimo considerado para General Purpose; HA desactivada.
Objetos	Blob Storage Hot LRS; 500 GB iniciales y crecimiento de 20% anual	Capacidad con crecimiento; operaciones y recuperaciones no se valorizan por falta de volumen.
Red	200 GB/mes de salida a Internet	Se descuentan los primeros 100 GB/mes y se aplica la tarifa continental.
Observabilidad	Azure Monitor Basic Logs; 50 GB/mes y 30 días	Se valoriza ingesta; consultas y retención adicional quedan fuera.
Respaldo	Backup automático de PostgreSQL por 7 días	Sin excedente sobre el almacenamiento provisionado, LTR ni redundancia geográfica.

5.4 Supuestos técnicos, operativos y económicos

Entrada	Valor utilizado	Estado	Validación
Precios cloud	Tarifas Azure de lista, por SKU, región y unidad; USD	Oficial	Refrescar antes de decidir
Horizonte y moneda	60 meses; USD constantes; sin impuestos ni inflación	Supuesto	Aprobación financiera
Demanda y capacidad	Producción: 1 M solicitudes/mes, 1 vCPU, 2 GiB y 730 h; no producción: 0,1 M, 0,5 vCPU, 1 GiB y 264 h	Supuesto documentado	Sustituir por telemetría
Datos y observabilidad	PostgreSQL GP: 2 vCores/100 GiB; Blob: 500 GB iniciales y 20% anual; logs: 50 GB/mes; backup: 7 días	Supuesto documentado	Validar consumo y retención
Red	200 GB/mes de egress; se descuentan 100 GB gratuitos	Supuesto documentado y regla oficial	Medir origen y destino
Escenario optimizado	No producción: 264 a 132 h/mes; logs: 50 a 40 GB/mes; egress: 200 a 160 GB/mes	Estimación de ingeniería	Validar con métricas y piloto
Tasa de descuento	5,5% anual, Tasa Social de Descuento 2026 del MDSF	Proxy público	Sustituir por WACC aprobado
Horas de implementación	50 h por alternativa regional, desglosadas bottom-up	Estimación de ingeniería	Validar con timesheets; no asignar a cada palanca sin desglose
Operación FinOps	1 h/mes por alternativa regional	Estimación de ingeniería	Validar con responsable y timesheets
Tarifa horaria	USD 8,53/h, derivada de ingreso neto, jornada y tipo de cambio públicos	Proxy público	Sustituir por costo empresa cargado
Costos por palanca y cargos excluidos	FP-184 no informa costo por palanca; faltan operaciones Blob y consultas/retención adicional de Monitor	Pendiente humano	Estimar horas y medir volúmenes
Disponibilidad y región	SLA público de PostgreSQL sin HA: 99,9%; línea base sin HA	Referencia oficial y supuesto	Aprobar SLO, HA y RPO/RTO
Latencia y residencia	No hay mediciones por región ni aprobación servicio por servicio	Pendiente humano	Medir latencia y revisar residencia

Los precios públicos de lista son verificables a la fecha de consulta, pero no equivalen a una factura negociada. La tasa de 5,5% es un proxy de la Tasa Social de Descuento, no el WACC de ONEBYTE; la tarifa de USD 8,53/h parte de ingreso neto promedio y no representa costo empresa con cargas y overhead. Las 50 horas de implementación y 1 h/mes de operación son estimaciones bottom-up, no horas observadas en timesheets. Por ello, la matriz distingue proxies públicos de estimaciones de ingeniería y mantiene los datos internos como pendientes; los resultados sirven para discusión académica, no para aprobar presupuesto.

De los 94 registros de la matriz, 25 corresponden a evidencia oficial, 25 a supuestos documentados, 3 a proxies públicos, 6 a estimaciones de ingeniería, 15 a resultados derivados, 17 a validaciones humanas pendientes y 3 a exclusiones justificadas. Los conteos describen registros trazables, no porcentajes de completitud ni aprobaciones.

5.5 Volumen de usuarios, solicitudes y almacenamiento

El modelo usa 1.000.000 de solicitudes mensuales en producción y 100.000 en no producción. La aplicación productiva permanece disponible 730 horas al mes, mientras el ambiente no productivo funciona 264 horas. Blob Storage parte con 500 GB y crece 20% anual; además se modelan 50 GB/mes de logs y 200 GB/mes de salida a Internet.

No se dispone de un número real de usuarios ni de una relación observada entre usuarios y solicitudes. Por esa razón, las solicitudes se usan como variable directa de demanda y no se calcula costo por usuario. En una validación posterior deberán incorporarse usuarios activos mensuales, solicitudes por usuario, percentiles de concurrencia y crecimiento observado.

5.6 Costo base mensual y anual

El workbook calcula cada mes por separado y refleja el crecimiento del almacenamiento. Para facilitar la lectura, la tabla siguiente muestra promedios equivalentes; estos promedios no sustituyen el detalle mensual reproducible.

Indicador	Chile Central	East US
TCO cloud base promedio mensual	USD 387,61	USD 274,58
TCO cloud base promedio anual	USD 4.651,26	USD 3.294,92
Costo cloud optimizado promedio mensual	USD 363,39	USD 258,97
Costo cloud optimizado promedio anual	USD 4.360,63	USD 3.107,62

5.7 Costo total de propiedad a cinco años

Indicador a 60 meses	Chile Central	East US
TCO cloud base	USD 23.256,32	USD 16.474,60
Ahorro bruto de las tres palancas	USD 1.453,15	USD 936,48
Costo cloud optimizado	USD 21.803,17	USD 15.538,12
Operación FinOps modelada	USD 512,07	USD 512,07
Implementación modelada	USD 426,73	USD 426,73
Costo comparable con proxies financieros	USD 22.741,97	USD 16.476,92

East US mantiene una ventaja de USD 6.265,05 incluso después de incorporar los mismos proxies de implementación y operación. Este valor compara alternativas regionales; no debe confundirse con el VAN incremental, que responde a una pregunta distinta: si conviene ejecutar el paquete de optimización dentro de cada región.

5.8 Aplicación de la primera palanca de optimización

La primera palanca reduce la ventana de no producción desde 264 a 132 horas mensuales. El cambio representa programación de apagado y escala a cero fuera de las ventanas aprobadas, no una reducción de capacidad productiva. El ahorro bruto a 60 meses es USD 598,75 en Chile Central y USD 427,68 en East US. Antes de aplicarla deben acordarse horarios de pruebas, soporte y excepciones.

5.9 Aplicación de la segunda palanca de optimización

La segunda palanca reduce la ingesta de Basic Logs desde 50 a 40 GB mensuales. El ahorro bruto es USD 420,00 en Chile Central y USD 300,00 en East US. La reducción solo es válida si se preservan los eventos necesarios para seguridad, diagnóstico y auditoría. En un piloto debe clasificarse cada fuente de log, medir

su volumen y verificar que la retención de 30 días sea suficiente.

5.10 Aplicación de la tercera palanca de optimización

La tercera palanca disminuye el egress modelado desde 200 a 160 GB mensuales mediante control de transferencias evitables y revisión de topología. La fórmula descuenta los primeros 100 GB mensuales antes de aplicar la tarifa, evitando cobrar tráfico cubierto por la franquicia. El ahorro bruto a 60 meses es USD 434,40 en Chile Central y USD 208,80 en East US. No se atribuye ahorro a caché, compresión o rediseño mientras su efecto no sea medido.

5.11 Comparación entre Santiago de Chile y Estados Unidos

Criterio	Chile Central	East US	Resultado
Costo total comparable	USD 22.741,97	USD 16.476,92	East US
Residencia de datos	Alternativa si se exige operar en Chile	Requiere autorización para operar fuera de Chile	Pendiente
Latencia	Proximidad esperada, no medida	Debe medirse desde usuarios objetivo	Pendiente
Backup georredundante	No incluido en el caso base	Disponible como opción regional distinta	No comparable sin rediseño
HA y SLA	Sin HA; requiere escenario separado	Sin HA; requiere escenario separado	Equivalente en la base

La recomendación económica predeterminada es East US cuando ambas regiones cumplen el mismo SLO y no existen restricciones de residencia, contrato o riesgo operativo. Chile Central debe seleccionarse si esas restricciones exigen operar en Chile. La región no se cierra sin medición de latencia y validación servicio por servicio de residencia, HA, backup y soporte.

5.12 Análisis de sensibilidad

El análisis reproduce las líneas facturables del TCO para ambas regiones y modifica una variable por vez. Las variables continuas se exploran en un rango de $\pm 20\%$, definido por el equipo como escenario y no extraído de los papers. PostgreSQL se evalúa con tamaños discretos General Purpose de 2, 4 y 8 vCores para evitar configuraciones fraccionarias no desplegables. El proceso verificó 1.440 celdas, totales, monotonicidad y consistencia del archivo fuente.

5.13 Variables de mayor impacto en la factura

Las dos variables con mayor efecto son los vCores de PostgreSQL en producción y la vCPU de Container Apps en producción. El resultado es coherente con la arquitectura: PostgreSQL mantiene capacidad provisionada, mientras la aplicación concentra la carga productiva. No se recomienda reducirlas directamente. Primero deben observarse CPU, memoria, conexiones, tiempo de respuesta, errores y throughput; luego se ejecuta una prueba controlada con criterio de reversa.

5.14 Relación con el flujo de caja, VAN y TIR

Indicador incremental	Chile Central	East US
VAN del paquete FinOps	USD 397,07	USD -55,21
TIR incremental anual	43,91%	-0,21%
Periodo de recuperación descontado	Mes 30	No recupera en 60 meses

El flujo incremental registra en el mes 0 el costo estimado de implementación y, durante los meses 1 a 60, el ahorro cloud menos una hora mensual estimada de operación FinOps. Con la tasa provisional de 5,5%, el paquete completo crea valor en Chile Central, pero no en East US bajo los mismos costos de trabajo. Esto no convierte a Chile en la región más barata: significa que el mayor ahorro potencial de Chile justifica la intervención modelada. Si se elige East US, el paquete debe reducir su esfuerzo, aumentar su ahorro o aplicarse por etapas hasta alcanzar un VAN no negativo. El PRI descontado se calcula de forma visible en FP-187 mediante el primer mes cuyo flujo incremental descontado acumulado es no negativo: Chile Central recupera en el mes 30 y East US no recupera dentro de 60 meses.

Siguiendo el análisis incremental del capítulo 7, sección 7.3, y los criterios VAN, TIR y PRI del capítulo 8, sección 8.2, esta evaluación responde si conviene ejecutar el paquete FinOps sobre la línea base cloud. No representa la viabilidad integral del negocio ONEBYTE: no incluye ingresos, impuestos, capital de trabajo ni una inversión de migración regional. Esos componentes requieren un alcance y datos empresariales distintos; además, el modelo mantiene explícitamente fuera impuestos e inflación.

5.15 Aporte propio aplicado al caso

El aporte del grupo consiste en integrar decisiones que normalmente se revisan por separado. El modelo conecta arquitectura, precios regionales, franquicias, crecimiento, palancas, sensibilidad y flujo de caja mediante fórmulas reproducibles. Antes de cerrar la recomendación quedan cuatro gates: (1) medir usuarios, solicitudes, concurrencia y consumos; (2) validar WACC, costo empresa, horas reales y costo de implementación por palanca; (3) aprobar SLO, latencia, HA/RPO/RTO, soporte y residencia por servicio; y (4) confirmar que el escenario ilustrativo representa el caso que el equipo defenderá.

Con la evidencia disponible, la decisión defendible es mantener la arquitectura de referencia para el análisis, usar East US como alternativa económica por defecto si supera los gates técnicos y reservar Chile Central para restricciones que requieran operar localmente. En cualquiera de las dos regiones deben aplicarse primero las palancas de bajo riesgo, medir el resultado y recalculan el TCO, VAN, TIR y PRI con consumo, horas y tasas validadas antes de una decisión contractual. La auditoría documental del 21-09-2026 confirmó que los 17 registros aún carecen de la medición, dato interno o aprobación formal requerida; por ello, esta conclusión sigue siendo condicionada y académica.

06

SÍNTESIS Y POSICIÓN DEL GRUPO

Discusión y conclusiones

- 6.1 Interpretación de los resultados
- 6.2 Discusión crítica de las alternativas
- 6.3 Relación entre arquitectura y costos
- 6.4 Limitaciones y riesgos del análisis
- 6.5 Principales aportes propios del grupo
- 6.6 Recomendación para ONEBYTE
- 6.7 Conclusiones

R

FUENTES VERIFICADAS

Referencias

A

EVALUACIÓN DE CONOCIMIENTOS

Cuestionario de 30 preguntas

A.1 Índice temático

A.2 Preguntas, respuestas y justificaciones

B

PROBIDAD Y TRAZABILIDAD

Declaración de uso de inteligencia artificial**B.1** Registro de uso por sección e integrante**B.2** Prompts y evidencia trazable**B.3** Declaraciones individuales y firmas